



Subdue compression with LPM

Progetto di Big data analytics e
Machine learning
UNIVPM A.A. 2021/2022

Introduzione



SubDue è un algoritmo di clustering gerarchico e concettuale, dove ogni cluster è descritto da un'etichetta e diviso in sotto-cluster.

SubDue comprime un grafo, sostituendo tutte le istanze di una sotto-struttura con un puntatore alla struttura stessa.

Introduzione



Per determinare il sotto-grafo candidato, il criterio di scelta di *Subdue* si basa sul principio della **Minimum Description Length (MDL)**:

$$\text{Compression} = \frac{DL(S) + DL(G|S)}{DL(G)}$$


- $DL(G)$ è la *Description Length* del grafo di input;
- $DL(S)$ è la *Description Length* della sotto-struttura;
- $DL(G|S)$ è la *Description Length* del grafo di input dal quale sono state eliminate tutte le istanze della sotto-struttura.

Introduzione



La *Description Length* di un grafo si calcola come il numero di bit necessari per codificare la *matrice di adiacenza*, ovvero la struttura dati che implementa il grafo al calcolatore.

La struttura scelta è quella che massimizza l'inverso di *Compression*.



	1	2	3	4	5	6
1	0	1	1	0	0	0
2	0	0	0	1	0	0
3	0	0	0	1	1	0
4	0	0	0	0	0	1
5	0	0	0	0	1	1
6	0	0	0	0	0	0

Obiettivi del progetto



Subdue consente di comprimere grafi, mentre, per i nostri scopi, è necessario comprimere un **file di log**; per questo motivo, si è reso necessario apportare le seguenti modifiche:

- ➔ La struttura dati in ingresso deve essere un *file di log*;
- ➔ Utilizzare una differente metrica di compressione che tenga conto del concetto di *traccia*;
- ➔ Il processo di sostituzione deve eliminare dal *file di log* gli eventi della sotto-struttura di interesse, sostituendo la prima occorrenza dell'evento con un'etichetta.

Workflow



01

Generazione
dei LMP

02

Etichettatura
degli eventi

03

Scelta del LPM

04


Eliminazione
del LPM
candidato

Generazione del LPM



Un **Local Process Model** è una *rete di Petri* che identifica e descrive un comportamento molto frequente all'interno *dell'event log*.

Tramite il framework **ProM**[\[1\]](#) sono stati generati i *LPM* da fornire in input all'algoritmo di etichettatura.



Etichettatura degli eventi



L'algoritmo di etichettatura è sintetizzabile nei seguenti passi:

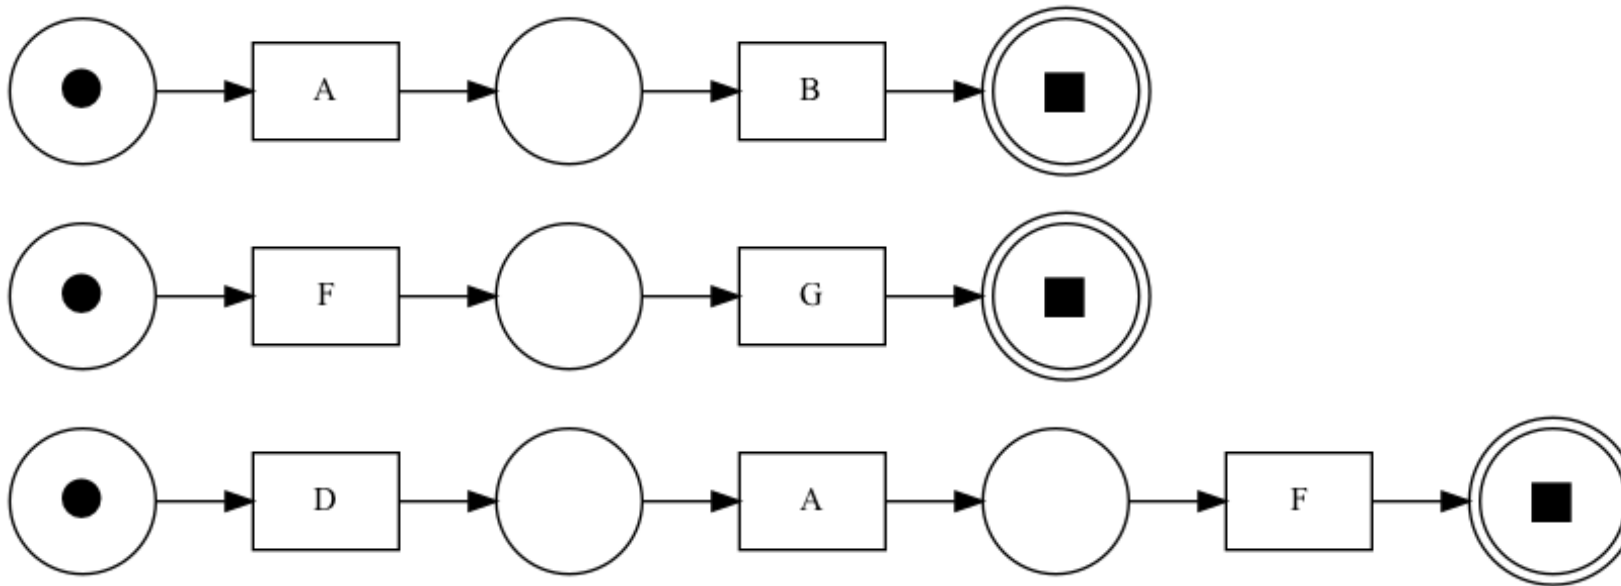
- Riceve in input il *file di log* in formato .xes ed i *LPM* precedentemente ottenuti;
- Restituisce in output il file .xes originale, dove ad ogni evento viene assegnata un lista contenente gli *LPM* in cui l'evento compare;

L'evento, per poter essere etichettato, deve comparire in una traccia che percorre interamente il LPM dallo stato iniziale a quello finale (traccia valida), altrimenti viene ignorato.

Esempio



$L = [< a, b, c, d, a, b >, < a, c, d, a >, < f, g, h, i >, < d, a, f, g >]$



$L = [< a(1), b(1), c, d, a(1), b(1) >, < a, c, d, a >, < f(2), g(2), h, i >, < d(3), a(3), f(2,3), g(2) >]$

Scelta del LPM



Per poter sostituire gli eventi nel *file di log*, è necessario definire una metrica per la compressione, alcune prese in considerazione sono:

- numero di eventi contrassegnati con il *LPM*: calcolata come il numero di eventi in cui occorre l'indice relativo al *LPM*;
- numero di tracce che percorrono il *LPM* moltiplicato per il numero di transizioni dello stesso; è il metodo che maggiormente si avvicina alla metrica utilizzata da *Subdue* e si calcola come:

$$N^{\circ} \text{ tracce} * \text{Dimensione LPM}$$

Scelta del LPM



In output otteniamo gli eventi che sono etichettati con gli indici dei LPM in cui occorrono, perciò la prima metrica è facile da calcolare, poiché basta scorrere il *file di log* e selezionare il LPM il cui indice compare il maggior numero di volte.

Inoltre, questa metrica definisce esattamente il numero degli eventi che verranno sostituiti, per cui si adatta meglio all'obiettivo del progetto.

Eliminazione del LPM


Dopo aver individuato il *LPM* candidato, si comprime il *file di log* scorrendolo e manipolando gli eventi:

- se l'evento corrente è il primo evento di una traccia valida per il *LPM* candidato, allora viene sostituito da un evento con il nome: «*LPM:numLPM_Iteration:numIterazione**», altrimenti viene eliminato;
- Inoltre, è necessario eliminare gli attributi «*LPMs_List*», «*LPMs_Binary*», «*LPMs_Frequency*» dell'evento, perché verrà etichettato di nuovo nella successiva iterazione.

Eliminazione del LPM: 2

Esempio 1

$$L = [< d(2), a(2), f(1,2), g(1), d(2), a(2), f(1,2) >]$$




$$Initial = [D], final = [F]$$

$$L = [< LPM: 2_0, g, LPM: 2_0 >]$$

Eliminazione del LPM: 1

Esempio 2

$$L = [< a(1), b(1), a(1), b(1), c, a(1), b(1) >]$$




$$Initial = [A], final = [B]$$

$$L = [< LPM:1_0, LPM:1_0, c, LPM:1_0 >]$$

Eliminazione del LPM: 1

Esempio 3

$$L = [< a(1), b(1), a(1), b(1), c, a(1), b(1) >]$$




$$Initial = [A], final = [B]$$

$$L = [< LPM:1_0, LPM:1_0, c, LPM:1_0 >]$$

Eliminazione del LPM: 1

Esempio 4

$$L = [< a(1), b(1), a(1), b(1), c, a(1), b(1) >]$$




$$Initial = [A], final = [B]$$

$$L = [< LPM:1_0, LPM:1_0, c, LPM:1_0 >]$$

Eliminazione del LPM: 1

Esempio 5

$$L = [< a(1), b(1), c, a(1), b(1), a >]$$




$$Initial = [A, B], final = [A, B]$$

$$L = [< LPM:1_0, c, LPM:1_0, a >]$$

Eliminazione del LPM: 1

Esempio 6

$$L = [\langle a(1), c, a(1), a(1) \rangle]$$




$$Initial = [A], final = [A]$$

$$L = [\langle LPM:1_0, c, LPM:1_0, LPM:1_0 \rangle]$$

Eliminazione del LPM: 1

Esempio 7

$$L = [< a(1), b(1), b(1), b(1), c, a(1), b(1) >]$$



$$Initial = [A], final = [A]$$

$$L = [< LPM: 1_0, c, LPM: 1_0 >]$$

Conclusioni e sviluppi futuri

L'obiettivo del seguente progetto è di realizzare un algoritmo di compressione che operi con la stessa logica di *Subdue*, accettando in input *file di log* anziché grafi.

Alcuni sviluppi futuri potrebbero coinvolgere:

- Ottimizzazione dell'algoritmo di etichettatura;
- Realizzazione di un programma che inglobi le fasi di generazione dei LPM (al momento realizzato tramite interfaccia grafica da ProM) ed il qui proposto algoritmo di compressione.